

Sistema de Monitoreo y Alerta Temprana basado en Inteligencia Artificial para Áreas Protegidas

Autores:

Fabrizio Martin Contigiani
Gabriel Orlando Da Silva Schmies

Tutor:

Dr. Ing. Sergio Eduardo Moya

28 de diciembre de 2025

Resumen

El presente trabajo describe el diseño e implementación de un sistema de monitoreo y alerta temprana para áreas protegidas de la Selva Misionera, que combina tecnologías de Internet de las Cosas (IoT) con Inteligencia Artificial (IA) para la detección automática de fauna silvestre, personas y vehículos.

El sistema está compuesto por una red de nodos de captura basados en microcontroladores ESP32 equipados con cámaras, los cuales se comunican mediante el protocolo ESP-MESH para transmitir imágenes hacia un nodo raíz. Este nodo actúa como puerta de enlace, reenviando las imágenes a un servidor remoto a través de Transmission Control Protocol (TCP)/IP.

En el servidor, las imágenes son procesadas por un servicio de inferencia basado en SpeciesNet, un modelo de detección de objetos desarrollado por Google que utiliza YOLOv5. Este modelo permite identificar y clasificar especies de fauna silvestre, así como detectar la presencia de humanos y vehículos, generando alertas automáticas ante posibles intrusiones.

La arquitectura del servidor incluye una aplicación web desarrollada en Django para la gestión de imágenes, un bot de Telegram para el envío de notificaciones en tiempo real, y una base de datos PostgreSQL para el almacenamiento persistente. Todo el sistema está contenedorizado mediante Docker para facilitar su despliegue.

Los resultados demuestran la viabilidad de implementar un sistema de vigilancia inteligente de bajo costo para áreas protegidas, capaz de operar de manera autónoma y alertar a los administradores ante eventos relevantes.

Palabras Clave - Cámaras Trampa, Internet de las Cosas, Inteligencia Artificial, Monitoreo de Fauna, Detección de Intrusos, ESP-MESH, SpeciesNet, Selva Misionera

Índice general

Índice de figuras	5
Índice de tablas	6
Glosario	7
Siglas	12
1. Introducción	13
1.1. Contexto y motivación	13
1.2. Estructura del documento	14
2. Antecedentes	15
2.1. Trabajos relacionados	15
2.2. Estado del arte	16
2.3. Soluciones comerciales existentes	17
2.4. Análisis comparativo	18
3. Planteamiento del Problema	19
3.1. Contexto regional	19
3.1.1. La Selva Misionera y el Bosque Atlántico	19
3.1.2. Biodiversidad y especies en peligro	19
3.1.3. Importancia ecológica de la región	20
3.2. Problemáticas de conservación en la región	20
3.2.1. Deforestación y fragmentación del hábitat	20
3.2.2. Caza furtiva y tráfico de fauna	21
3.2.3. Intrusión en áreas protegidas	21
3.2.4. Desafíos de la vigilancia en el terreno	21
3.3. Sistemas de monitoreo actuales	22
3.3.1. Cámaras trampa convencionales	22
3.3.2. Patrullajes terrestres	23
3.3.3. Brechas tecnológicas identificadas	23
3.4. Justificación del proyecto	23
3.4.1. Urgencia de la problemática	23
3.4.2. Oportunidad tecnológica	24
3.4.3. Requisitos del sistema propuesto	24

4. Objetivos y Alcance	25
4.1. Objetivo general	25
4.2. Objetivos específicos	25
4.3. Alcance del proyecto	26
4.3.1. Dentro del alcance	26
4.3.2. Fuera del alcance	26
4.4. Limitaciones	26
4.4.1. Limitaciones de hardware	26
4.4.2. Consideraciones sobre el tiempo de respuesta	27
4.4.3. Limitaciones de alcance	27
5. Marco Teórico	28
5.1. Internet de las Cosas (IoT)	28
5.1.1. Arquitecturas IoT	28
5.1.2. Protocolos de comunicación inalámbrica	28
5.2. Redes Mesh	29
5.2.1. Topologías de red	29
5.2.2. ESP-MESH: características técnicas	30
5.2.3. Componente Mwifi del ESP-MDF	30
5.3. Inteligencia Artificial aplicada a visión por computadora	30
5.3.1. Redes neuronales convolucionales (CNN)	31
5.3.2. Detección de objetos con YOLO	31
5.3.3. MegaDetector	31
5.3.4. SpeciesNet de Google	31
5.4. Tecnologías de desarrollo	32
5.4.1. Microcontroladores ESP32	32
5.4.2. ESP-IDF y ESP-MDF	32
5.4.3. Contenedorización con Docker	33
5.4.4. Framework Django	33
5.5. Sensores y actuadores	33
5.5.1. Sensores de movimiento PIR	33
5.5.2. Módulos de cámara OV2640	33
5.6. Diseño y fabricación digital	34
5.6.1. Modelado 3D	34
5.6.2. Fabricación aditiva	34
6. Metodología	35
6.1. Enfoque metodológico	35
6.2. Etapas del desarrollo	35
6.3. Herramientas y tecnologías utilizadas	36
6.3.1. Entorno de desarrollo	36
6.3.2. Diseño y fabricación 3D	36
6.3.3. Control de versiones y despliegue	37
6.3.4. Despliegue continuo	37
6.4. Métricas de evaluación	37
6.4.1. Métricas de rendimiento de red	37
6.4.2. Métricas de clasificación	38

6.4.3.	Métricas de consumo energético	38
6.5.	Estrategia de pruebas	38
6.5.1.	Pruebas incrementales de firmware	38
6.5.2.	Pruebas de integración	38
6.5.3.	Pruebas de sistema	38
7.	Diseño e Implementación del Sistema	40
7.1.	Arquitectura general	41
7.2.	Nodo de cámara (mesh-node)	41
7.2.1.	Selección de componentes	41
7.2.2.	Diseño del firmware	41
7.2.3.	Captura de imágenes	41
7.2.4.	Integración del sensor PIR	41
7.2.5.	Compresión y transmisión	41
7.2.6.	Carcasa para impresión 3D	41
7.3.	Nodo raíz (root-node)	41
7.3.1.	Diseño del hardware	41
7.3.2.	Firmware del nodo raíz	41
7.3.3.	Conexión con servidor TCP	41
7.3.4.	Gestión de la red mesh	41
7.4.	Red mesh	41
7.4.1.	Topología de la red	41
7.4.2.	Protocolo de comunicación	41
7.4.3.	Formato de datos	41
7.5.	Servicio de detección (wildlife-detection)	41
7.5.1.	Arquitectura del servicio	41
7.5.2.	Contenedor Docker con SpeciesNet	41
7.5.3.	API de inferencia	41
7.5.4.	Detección y clasificación	41
7.6.	Servidor de aplicación (server)	41
7.6.1.	Arquitectura Django	41
7.6.2.	Gestión de imágenes	41
7.6.3.	Bot de Telegram y sistema de alertas	41
7.6.4.	Base de datos PostgreSQL	41
7.6.5.	Despliegue con Docker Compose	41
7.7.	Alimentación y consumo energético	41
8.	Pruebas y Resultados	42
8.1.	Ambiente de pruebas	42
8.2.	Pruebas de conectividad y red mesh	42
8.2.1.	Alcance de la red	42
8.2.2.	Latencia de transmisión	42
8.2.3.	Estabilidad de la conexión	42
8.3.	Pruebas de detección	42
8.3.1.	Detección de fauna silvestre	42
8.3.2.	Detección de humanos	42
8.3.3.	Detección de vehículos	42

8.4.	Evaluación del modelo de IA	42
8.4.1.	Precisión y recall	42
8.4.2.	Tiempo de inferencia	42
8.5.	Pruebas de consumo energético	42
8.6.	Pruebas del sistema de alertas	42
8.6.1.	Tiempo de respuesta	42
8.7.	Análisis de resultados	42
9.	Conclusiones	43
9.1.	Conclusiones generales	43
9.2.	Aportes del trabajo	43
9.3.	Trabajos futuros	43
9.4.	Recomendaciones	43
10.	Bibliografía	44
A.	Esquemáticos del hardware	47
B.	Código fuente relevante	48
B.1.	Firmware del nodo mesh	48
B.2.	Firmware del nodo raíz	48
B.3.	Servidor de detección	48
B.4.	Aplicación Django	48
C.	Manual de instalación y configuración	49
C.1.	Configuración del firmware	49
C.2.	Despliegue del servidor	49
C.3.	Configuración del bot de Telegram	49
D.	Manual de usuario	50
E.	Especificaciones técnicas	51
F.	Análisis de viabilidad económica	52

Índice de figuras

6.1. Cronograma de desarrollo del proyecto.	36
---	----

Índice de tablas

2.1. Comparativa de soluciones de monitoreo y trabajos relacionados.	18
--	----

Glosario

alerta temprana Sistema de detección y notificación que permite identificar y comunicar eventos críticos con mínima latencia, posibilitando respuestas preventivas antes de que el daño se materialice. 21

AP-STA Modo de operación en el que un dispositivo actúa simultáneamente como Punto de Acceso (AP) y Estación (STA). 29

aprendizaje automático Rama de la inteligencia artificial que permite a los sistemas aprender y mejorar automáticamente a partir de datos sin ser programados explícitamente, también conocido como machine learning. 15, 16, 30

autocuración Capacidad de una red mesh para reconfigurarse automáticamente cuando un nodo falla, permitiendo que los nodos afectados encuentren rutas alternativas sin intervención manual. 30

batería 18650 Celda de batería de iones de litio con formato cilíndrico de 18mm de diámetro y 65mm de longitud. Ampliamente utilizada en dispositivos electrónicos portátiles por su alta densidad energética y capacidad de recarga. 26, 34

Bosque Atlántico Ecorregión de bosques subtropicales húmedos que se extiende por Brasil, Paraguay y Argentina, conocida también como Mata Atlántica, uno de los biomas más biodiversos del planeta. 19, 23

bot de Telegram Programa automatizado que interactúa con usuarios a través de la plataforma de mensajería Telegram. 1, 13, 26, 38

bounding box Rectángulo que delimita la ubicación de un objeto detectado en una imagen. 31

CAD Diseño Asistido por Computadora (Computer-Aided Design), software utilizado para crear modelos 2D y 3D de objetos. 34

callback Función que se pasa como argumento a otra función y que será invocada cuando ocurra un evento específico, permitiendo la programación asíncrona y orientada a eventos. 30

cámara trampa Dispositivo de captura de imágenes activado por movimiento, utilizado comúnmente para monitoreo de fauna silvestre. 13, 15, 16, 17, 22, 24, 25, 27, 28, 30, 31

- carcasa** Estructura protectora que alberga los componentes electrónicos de un dispositivo, protegiéndolos del ambiente externo. 34, 36
- caza furtiva** Práctica ilegal de captura o matanza de animales silvestres sin autorización, a menudo de especies protegidas o en peligro de extinción. 13, 14, 18, 20, 21, 23, 24
- clasificación taxonómica** Proceso de identificar y categorizar organismos biológicos en grupos jerárquicos como familia, género y especie. 15, 17, 25, 31
- código G** Lenguaje de programación utilizado para controlar máquinas de fabricación por control numérico, incluyendo impresoras 3D. Define la trayectoria de la herramienta, velocidades y temperaturas. 36
- código abierto** Software cuyo código fuente está disponible públicamente para que cualquiera pueda estudiarlo, modificarlo y distribuirlo. 14, 16, 17, 24, 31, 32
- convertidor buck** Circuito regulador de voltaje de tipo reductor (step-down) que convierte un voltaje de entrada mayor a un voltaje de salida menor con alta eficiencia. Utilizado para alimentar dispositivos electrónicos desde baterías de mayor voltaje. 26, 34
- Corredor Verde** Corredor biológico de aproximadamente 1.1 millones de hectáreas en la provincia de Misiones, Argentina, que conecta áreas protegidas para permitir el desplazamiento de fauna silvestre y mantener la conectividad genética de las poblaciones. 19, 20, 23
- deep sleep** Modo de bajo consumo extremo en microcontroladores donde la mayoría de los periféricos y el procesador principal se apagan, manteniendo solo un núcleo mínimo capaz de despertar el sistema ante eventos externos como señales de sensores o temporizadores. 32
- despliegue continuo** Práctica de ingeniería de software que automatiza el proceso de publicación de cambios de código a producción, permitiendo entregas frecuentes y confiables. También conocido como Continuous Deployment (CD). 37
- detección de objetos** Técnica de visión por computadora que identifica y localiza objetos dentro de una imagen, generalmente mediante bounding boxes. 13, 15, 31
- Django** Framework de desarrollo web de alto nivel escrito en Python, que sigue el patrón modelo-vista-plantilla. 1, 28, 33, 35, 36
- Docker** Plataforma de contenedorización que permite empaquetar aplicaciones junto con sus dependencias para facilitar el despliegue. 1, 33, 36, 37
- Docker Compose** Herramienta para definir y ejecutar aplicaciones Docker multi-contenedor mediante archivos YAML. 33, 36
- edge computing** Paradigma de computación distribuida que acerca el procesamiento y el almacenamiento de datos a la ubicación donde se necesitan, con el fin de mejorar los tiempos de respuesta y ahorrar ancho de banda, también conocido como computación en el borde. 16, 18

- ESP-IDF** Espressif IoT Development Framework, entorno oficial de desarrollo para microcontroladores ESP32. 32, 36
- ESP-MDF** Espressif Mesh Development Framework, framework para desarrollo de redes mesh sobre ESP-IDF. 27, 30, 32, 36
- ESP-MESH** Protocolo de red mesh desarrollado por Espressif para microcontroladores ESP32, basado en Wi-Fi. 1, 13, 24, 25, 27, 28, 29, 30
- ESP32** Microcontrolador de bajo costo y bajo consumo con Wi-Fi y Bluetooth integrados, fabricado por Espressif Systems. 1, 13, 16, 18, 24, 25, 26, 28, 30, 32, 35, 36
- firmware** Software de bajo nivel almacenado en la memoria de un dispositivo que controla su funcionamiento básico. 32, 35, 37, 38
- fragmentación del hábitat** Proceso por el cual un ecosistema continuo se divide en parches aislados, reduciendo la conectividad entre poblaciones de especies y afectando su viabilidad genética y capacidad de dispersión. 21
- Git** Sistema de control de versiones distribuido de código abierto, diseñado para gestionar proyectos de software de cualquier tamaño con velocidad y eficiencia. 37
- GitHub Actions** Plataforma de integración y despliegue continuo (CI/CD) integrada en GitHub que permite automatizar flujos de trabajo de desarrollo, pruebas y despliegue. 37
- grado de protección IP** Código estándar definido por la norma IEC 60529 que indica el nivel de protección de un dispositivo contra la intrusión de sólidos (primer dígito) y líquidos (segundo dígito). Por ejemplo, IP67 indica protección total contra polvo y contra inmersión temporal en agua. 26
- hotspot de biodiversidad** Región biogeográfica que alberga una concentración excepcional de especies endémicas y que ha experimentado una pérdida significativa de hábitat, concepto introducido por Norman Myers en 1988. 19
- impresión 3D** Proceso de fabricación aditiva que crea objetos tridimensionales mediante la deposición de material capa por capa. 34
- inferencia** Proceso de utilizar un modelo de aprendizaje automático entrenado para realizar predicciones sobre nuevos datos. 1, 16
- Kanban** Metodología ágil de gestión de proyectos que visualiza el flujo de trabajo mediante un tablero con columnas, limita el trabajo en progreso y promueve la entrega continua de valor. 35
- LoRa** Tecnología de comunicación inalámbrica de largo alcance (Long Range) y bajo consumo de energía, que utiliza modulación por espectro ensanchado. 16, 18
- LoRaWAN** Protocolo de red que utiliza la tecnología LoRa para conectar dispositivos a internet, optimizado para bajo consumo y comunicaciones de largo alcance. 16

- Mata Atlántica** Nombre en portugués del Bosque Atlántico, utilizado principalmente en Brasil donde se encuentra el 92 % de la extensión original de este bioma. 19
- MegaDetector** Modelo de detección de objetos desarrollado por Microsoft para identificar automáticamente animales, personas y vehículos en imágenes de cámaras trampa. 17, 24, 25, 31
- mesh** Topología de red donde cada nodo puede conectarse con múltiples nodos vecinos, permitiendo rutas alternativas para la transmisión de datos. 14, 15, 16, 18, 24, 25, 26, 27, 29, 33, 34, 35, 37, 38
- Monumento Natural** Categoría de protección legal en Argentina que confiere a una especie o área natural el máximo nivel de protección, prohibiendo cualquier forma de caza, captura o comercio. 19
- Mwifi** Componente del ESP-MDF que proporciona APIs de alto nivel para comunicación en redes ESP-MESH. 30, 32
- nodo** Dispositivo individual que forma parte de una red mesh. 1, 29
- nodo raíz** Nodo principal de una red mesh que actúa como puerta de enlace hacia redes externas. 1, 29
- PostgreSQL** Sistema de gestión de bases de datos relacional de código abierto. 1, 33
- PyTorch** Biblioteca de aprendizaje automático de código abierto basada en la biblioteca Torch, utilizada para aplicaciones como visión computacional y procesamiento de lenguaje natural. 17, 31
- reserva de biosfera** Área protegida reconocida por la UNESCO bajo el programa El Hombre y la Biosfera (MAB), que integra conservación de la biodiversidad con uso sostenible de recursos naturales. 21
- selva paranaense** Nombre alternativo para la Selva Misionera, que forma parte del bioma del Bosque Atlántico y se extiende por la cuenca del río Paraná en Argentina, Paraguay y Brasil. 19
- Selva Misionera** Porción argentina del Bosque Atlántico, ubicada principalmente en la Provincia de Misiones, caracterizada por su alta biodiversidad y vegetación subtropical. 1, 13, 18, 19, 20, 21, 23, 27
- sensor PIR** Sensor de Infrarrojo Pasivo que detecta cambios en la radiación infrarroja emitida por objetos en movimiento, comúnmente utilizado para detectar presencia de animales o personas. 22, 33
- servicios ecosistémicos** Beneficios que los ecosistemas proporcionan a la sociedad humana, incluyendo regulación climática, provisión de agua limpia, control de erosión, polinización y secuestro de carbono. 20

SpeciesNet Modelo de detección y clasificación de fauna silvestre desarrollado por Google, basado en YOLOv5. 1, 13, 15, 17, 24, 25, 28, 31, 33, 35

tiempo real Procesamiento de datos que ocurre con latencia mínima, permitiendo respuestas inmediatas a eventos. 13, 14, 15, 16, 18, 22, 23, 27

tráfico de fauna Comercio ilegal de animales silvestres vivos o sus partes, considerado la cuarta actividad ilícita más lucrativa a nivel mundial y una de las principales causas de pérdida de biodiversidad. 21

visión por computadora Campo de la inteligencia artificial que permite a las computadoras interpretar y comprender información visual del mundo real. 14, 15, 30

YOLOv5 Versión 5 del modelo You Only Look Once, arquitectura de red neuronal para detección de objetos en tiempo real. 1, 15, 16, 31

Siglas

ASA Acrilonitrilo Estireno Acrilato. 34

CNN Red Neuronal Convolutacional. 15, 31

FDM Modelado por Deposición Fundida. 34

FreeRTOS Free Real-Time Operating System. 32

IA Inteligencia Artificial. 1, 13, 14, 15, 16, 17, 18, 22, 23, 24, 25, 26, 27, 28, 31, 33, 38

IoT Internet de las Cosas. 1, 13, 14, 28

IR Infrarrojo. 22, 27, 34

JPEG Joint Photographic Experts Group. 33

OTA Over-The-Air. 32

PETG Tereftalato de Polietileno Glicol. 34

PIR Infrarrojo Pasivo. 22, 25, 26, 27, 28, 35, 38

PLA Ácido Poliláctico. 34, 36

RSSI Received Signal Strength Indicator. 30

SoC System on Chip. 32

TCP Transmission Control Protocol. 1, 30

YOLO You Only Look Once. 15, 16, 31

Capítulo 1

Introducción

La conservación de la fauna silvestre y la protección de áreas naturales representan desafíos críticos en la actualidad. En regiones de alta biodiversidad como la Selva Misionera, la pérdida de hábitat, la caza furtiva y la intrusión humana en ecosistemas protegidos amenazan el equilibrio ecológico y la supervivencia de numerosas especies. Ante esta problemática, surge la necesidad de implementar sistemas de monitoreo que permitan vigilar estas áreas de manera continua y eficiente.

Tradicionalmente, el monitoreo de fauna silvestre se ha realizado mediante cámara trampa, dispositivos que capturan imágenes cuando detectan movimiento. Sin embargo, estos sistemas convencionales presentan limitaciones significativas: requieren revisión manual periódica, no permiten alertas en tiempo real, y generan grandes volúmenes de datos que deben ser analizados manualmente por expertos.

El avance de tecnologías como el IoT y la IA ofrece nuevas posibilidades para superar estas limitaciones. La combinación de redes de sensores inalámbricos con algoritmos de detección de objetos permite desarrollar sistemas capaces de identificar automáticamente fauna silvestre, personas y vehículos, generando alertas inmediatas ante eventos relevantes.

El presente trabajo, desarrollado en el marco de la Universidad Nacional de Misiones, propone el diseño e implementación de un sistema de monitoreo y alerta temprana para áreas protegidas de la región, que integra una red de nodos de captura basados en ESP32 comunicados mediante ESP-MESH, un servidor de procesamiento con IA basado en SpeciesNet, y un sistema de notificaciones a través de bot de Telegram.

1.1. Contexto y motivación

Las áreas protegidas enfrentan amenazas constantes que van desde la caza ilegal de especies en peligro hasta la intrusión de personas no autorizadas y vehículos en zonas restringidas. Los guardaparques y administradores de estas áreas frecuentemente carecen de los recursos humanos y tecnológicos necesarios para mantener una vigilancia efectiva sobre extensas superficies de terreno, muchas veces en ubicaciones remotas con acceso limitado a infraestructura de comunicaciones.

Las cámaras trampa tradicionales, aunque útiles para la investigación científica, no fueron diseñadas para la vigilancia en tiempo real. Las imágenes capturadas permanecen almacenadas en tarjetas de memoria que deben ser recolectadas físicamente, lo que implica visitas frecuentes al campo y retrasos significativos entre la captura de un evento y su descubrimiento. Para

cuando se detecta una intrusión o un acto de caza furtiva, los responsables ya se encuentran lejos del área.

Es cierto que en la actualidad existen cámaras trampa más modernas que incorporan conectividad celular o satelital, permitiendo el envío remoto de imágenes. Sin embargo, estos dispositivos suelen tener un costo significativamente mayor, lo que limita su adopción masiva especialmente en países en vías de desarrollo, donde paradójicamente se concentra gran parte de la biodiversidad mundial. Además, muchas de estas soluciones comerciales dependen de servicios en la nube propietarios con costos de suscripción recurrentes.

La motivación de este proyecto surge de la necesidad de transformar el paradigma del monitoreo pasivo hacia un sistema activo de vigilancia inteligente, pero de manera accesible y de bajo costo. Un sistema que no solo capture imágenes, sino que las transmita en tiempo real, las analice automáticamente mediante algoritmos de IA, y genere alertas inmediatas cuando se detecten eventos de interés, ya sea la presencia de fauna silvestre para fines de investigación, o la detección de intrusos para fines de seguridad. Todo esto utilizando componentes de hardware económicos y software de código abierto.

1.2. Estructura del documento

El presente documento se organiza en nueve capítulos que describen de manera progresiva el desarrollo del sistema propuesto:

Capítulo 1 - Introducción: Presenta el contexto general del proyecto, la motivación y la estructura del documento.

Capítulo 2 - Antecedentes: Revisa trabajos relacionados, soluciones comerciales existentes y el estado del arte en sistemas de monitoreo de fauna y detección de intrusos.

Capítulo 3 - Planteamiento del Problema: Describe la problemática de las áreas protegidas, las limitaciones de los sistemas tradicionales y la justificación del proyecto.

Capítulo 4 - Objetivos y Alcance: Define los objetivos generales y específicos, así como el alcance y las limitaciones del trabajo.

Capítulo 5 - Marco Teórico: Presenta los fundamentos teóricos sobre IoT, redes mesh, IA aplicada a visión por computadora, y las tecnologías utilizadas.

Capítulo 6 - Metodología: Describe el enfoque metodológico, las etapas de desarrollo, las herramientas empleadas y las métricas de evaluación.

Capítulo 7 - Diseño e Implementación: Detalla la arquitectura del sistema, el diseño e implementación de cada componente: nodos de cámara, nodo raíz, red mesh, servicio de detección y servidor de aplicación.

Capítulo 8 - Pruebas y Resultados: Documenta las pruebas realizadas y analiza los resultados obtenidos en conectividad, detección, rendimiento y consumo energético.

Capítulo 9 - Conclusiones: Resume las conclusiones generales, los aportes del trabajo, trabajos futuros y recomendaciones.

Capítulo 2

Antecedentes

En los últimos años, el campo de la IA aplicada a la visión por computadora ha experimentado avances significativos. El desarrollo de arquitecturas de Redes Neuronales Convolucionales (CNNs) cada vez más eficientes, junto con la disponibilidad de grandes conjuntos de datos de entrenamiento, ha permitido crear modelos capaces de detectar y clasificar objetos en imágenes con una precisión sin precedentes [1]. Algoritmos como You Only Look Once (YOLO) [2] y sus sucesivas versiones, incluyendo YOLOv5 [3], han revolucionado la detección de objetos, permitiendo el procesamiento en tiempo real incluso en dispositivos con recursos limitados.

En el ámbito específico del monitoreo de fauna silvestre, estos avances han dado lugar a modelos especializados como SpeciesNet, desarrollado por Google [4], que combina detección de objetos con clasificación taxonómica para identificar especies a partir de imágenes de cámara trampa. Estos desarrollos han abierto nuevas posibilidades para automatizar el análisis de las enormes cantidades de imágenes que generan los sistemas de monitoreo.

Paralelamente, la tecnología de cámara trampa ha evolucionado desde dispositivos autónomos que almacenan imágenes localmente, hasta sistemas más sofisticados con conectividad celular o satelital que permiten la transmisión remota de datos. Este capítulo examina tanto los avances en IA aplicada a la visión por computadora, como la evolución de las soluciones de monitoreo de fauna, incluyendo sistemas comerciales y proyectos de investigación relacionados.

2.1. Trabajos relacionados

En el ámbito local, Barrero y Schmunck [5] desarrollaron en la Universidad Nacional de Misiones una microcámara de vigilancia orientada a la protección de fauna salvaje. Este trabajo propuso el diseño de un dispositivo compacto basado en microcontroladores capaz de capturar imágenes en áreas naturales. El proyecto sentó las bases para el desarrollo de soluciones de bajo costo adaptadas a las necesidades específicas de la región misionera, demostrando la viabilidad de utilizar hardware económico para aplicaciones de monitoreo ambiental. El presente trabajo extiende estos conceptos incorporando comunicación en red mesh, procesamiento con IA y un sistema de alertas en tiempo real.

En el contexto regional argentino, González et al. [6] presentaron en el Workshop de Investigadores en Ciencias de la Computación (WICC 2022) un sistema de IA para la multi-clasificación de fauna en fotografías automáticas utilizadas en investigación científica. Este trabajo demuestra el creciente interés en la comunidad científica argentina por aplicar técnicas de aprendizaje automático al análisis de imágenes de cámara trampa, estableciendo un

precedente importante para proyectos de monitoreo de fauna en el país.

En el contexto internacional, diversos trabajos han explorado el uso de YOLOv5 para el análisis automatizado de imágenes de cámara trampa. Abood et al. [7] presentaron un enfoque innovador en la conferencia IEEE ICMNWC 2023, demostrando que los modelos de la familia YOLO pueden adaptarse eficazmente para la detección y clasificación de fauna silvestre. Los autores destacaron las ventajas de YOLOv5 en términos de velocidad de inferencia y precisión. De manera similar, Njathi et al. [8] propusieron en IEEE AFRICON 2023 un sistema eficiente de anotación de imágenes de cámaras trampa basado en YOLOv5, enfocándose en reducir el tiempo y esfuerzo requerido para etiquetar grandes conjuntos de datos. Ambos trabajos evidencian la idoneidad de los modelos YOLO para aplicaciones de monitoreo de fauna que requieren procesamiento eficiente de grandes volúmenes de imágenes.

Un antecedente particularmente relevante para el presente trabajo es el sistema propuesto por Whytock et al. [9], quienes desarrollaron cámaras trampa con IA capaces de enviar alertas en tiempo real a través de la red satelital Iridium. El estudio, realizado en Gabón (África Central), demostró la viabilidad de integrar procesamiento con IA directamente en dispositivos de campo para detectar fauna y enviar notificaciones inmediatas a investigadores y guardaparques. Aunque su solución utiliza conectividad satelital —con costos operativos significativos—, el concepto de alertas en tiempo real basadas en detección automática constituye un pilar fundamental del sistema propuesto en este trabajo. La diferencia principal radica en que nuestra solución emplea redes mesh locales y conectividad Wi-Fi/TCP, reduciendo considerablemente los costos de operación.

Otro proyecto directamente comparable es AiCatcher, desarrollado por Mallya [10], que propone una cámara trampa inteligente capaz de realizar inferencia directamente en el dispositivo de campo. AiCatcher utiliza una Raspberry Pi como unidad de procesamiento para ejecutar modelos de detección en el borde (edge computing), y emplea módulos LoRa (Adafruit LoRa Bonnets) configurados en una red LoRaWAN para la transmisión de datos, convirtiendo las señales recibidas en mensajes SMS mediante Twilio. Si bien este enfoque es innovador, el uso de Raspberry Pi presenta un consumo energético significativamente mayor, limitando la autonomía del dispositivo en campo. En contraste, nuestra solución emplea microcontroladores ESP32 de bajo consumo para la captura y transmisión, delegando el procesamiento de IA a un servidor remoto. Además, el uso de redes mesh en nuestra propuesta permite una topología de red más flexible y autoorganizada.

2.2. Estado del arte

Vélez et al. [11] realizaron una evaluación exhaustiva de las plataformas disponibles para el procesamiento de imágenes de cámara trampa utilizando IA. Su estudio, publicado en *Methods in Ecology and Evolution*, comparó múltiples herramientas en términos de precisión, facilidad de uso y requisitos computacionales. Los autores concluyeron que, si bien existen diversas opciones de código abierto y comerciales, la elección de la plataforma adecuada depende del contexto específico de cada proyecto, incluyendo el volumen de imágenes, las especies objetivo y los recursos disponibles. Este análisis proporciona un marco de referencia valioso para la selección de tecnologías en proyectos de monitoreo de fauna.

Tabak et al. [12] demostraron la aplicabilidad del aprendizaje automático para clasificar especies animales en imágenes de cámaras trampa, alcanzando precisiones superiores al 90 % en la identificación de especies comunes. Su trabajo destacó la importancia de contar con

conjuntos de datos de entrenamiento representativos de las condiciones locales para optimizar el rendimiento de los modelos.

Por su parte, Steenweg et al. [13] abordaron el desafío de escalar las redes de cámara trampa para el monitoreo de biodiversidad a nivel global. Los autores argumentaron que la integración de sensores remotos en redes coordinadas, combinada con técnicas de análisis automatizado, representa el futuro del monitoreo de fauna silvestre, permitiendo obtener datos de biodiversidad a escalas espaciales y temporales sin precedentes.

Entre las plataformas más recientes, Hernández et al. [14] presentaron PyTorch-Wildlife, un framework colaborativo de aprendizaje profundo desarrollado por Microsoft AI for Good. Esta plataforma, similar en objetivos a SpeciesNet de Google, ofrece modelos preentrenados para la detección y clasificación de fauna silvestre en imágenes de cámara trampa. PyTorch-Wildlife se distingue por su enfoque en la facilidad de uso y la integración con el ecosistema PyTorch, facilitando tanto el despliegue de modelos existentes como el entrenamiento de modelos personalizados para especies específicas. La existencia de múltiples frameworks de código abierto respaldados por grandes empresas tecnológicas evidencia la relevancia del problema y la madurez de las soluciones disponibles.

Cabe destacar también MegaDetector, desarrollado originalmente por Microsoft AI for Earth [15], que se ha convertido en una herramienta fundamental en el procesamiento de imágenes de cámara trampa. A diferencia de los clasificadores de especies, MegaDetector se especializa en la detección genérica de animales, humanos y vehículos, funcionando como un primer filtro que reduce drásticamente el volumen de imágenes a analizar. Esta herramienta ha sido adoptada por más de 60 organizaciones de conservación a nivel mundial, demostrando reducciones de hasta el 90 % en el tiempo de procesamiento de datos. Su arquitectura modular permite integrarlo como etapa previa a clasificadores más específicos como SpeciesNet.

2.3. Soluciones comerciales existentes

En el mercado actual, existen diversas soluciones comerciales diseñadas para el monitoreo remoto de fauna. Las cámaras trampa con conectividad celular, como las series REVEAL de Tactacam [16] y las líneas Flex de Spypoint [17], son las más extendidas. Estos dispositivos permiten capturar imágenes de alta resolución y enviarlas a través de redes LTE a una aplicación móvil propietaria. Algunas de sus características principales incluyen disparo rápido (menor a 0.5 segundos), visión nocturna por infrarrojos y, en modelos recientes, la capacidad de solicitar fotografías o videos bajo demanda.

Sin embargo, estas soluciones presentan limitaciones críticas para su adopción masiva en proyectos de conservación a gran escala o en regiones remotas. En primer lugar, dependen enteramente de la infraestructura de red celular; en áreas de selva densa como la de Misiones, la falta de cobertura inalámbrica en el interior de las reservas suele ser la norma, invalidando el uso de estos dispositivos para alertas remotas. En segundo lugar, el costo operativo es elevado, ya que además de que cada cámara en sí tiene un costo de adquisición significativo, cada dispositivo requiere un plan de datos independiente, con suscripciones mensuales que pueden oscilar entre los 5 y 15 dólares por unidad [16], [17].

En cuanto a la gestión de datos, plataformas como Wildlife Insights [18] ofrecen una infraestructura robusta basada en la nube para el almacenamiento y análisis de imágenes mediante IA. Esta herramienta permite filtrar imágenes vacías automáticamente y realizar la clasificación taxonómica de especies, facilitando la colaboración entre investigadores. No obstante, Wildlife

Insights está orientada principalmente al procesamiento posterior (post-hoc) de los datos recolectados manualmente de las tarjetas SD, y no está diseñada para la vigilancia y respuesta inmediata ante eventos de intrusión o caza furtiva en tiempo real.

2.4. Análisis comparativo

A fin de situar las necesidades identificadas frente a las alternativas y trabajos discutidos anteriormente, se presenta a continuación un análisis comparativo que resume las principales diferencias técnicas y operativas. En la tabla 2.1 se contrastan las características de las categorías de soluciones analizadas: cámaras trampa tradicionales, soluciones comerciales celulares [16], [17], el sistema satelital de Whytock et al. [9] y el enfoque basado en edge computing de Mallya (AiCatcher) [10].

Tabla 2.1: Comparativa de soluciones de monitoreo y trabajos relacionados.

Característica	Tradicional	Celular [16]	Satelital [9]	LoRa [10]
Alertas en tiempo real	No	Sí	Sí	Sí
Infraestructura requerida	Ninguna	Operador Celular	Red Satelital	Puerta de enlace LoRa
Procesamiento de IA	Post-hoc	No / Limitado	Edge (Hardware Dedicado)	Edge (Raspberry Pi)
Costo de adquisición	Bajo-Medio	Medio-Alto	Muy Alto	Medio-Alto
Costo Operativo	Bajo	Alto (Plan mensual)	Muy Alto (Iridium)	Bajo (SMS/Twilio)
Autonomía energética	Muy Alta	Media	Media-Baja	Baja (Raspberry Pi)
Escalabilidad	Laboriosa	Por suscripción	Costo-prohibitiva	Media (LoRa)
Dependencia de terceros	No	Muy Alta	Muy Alta	Media (Twilio)

Como se desprende de la comparación, si bien existen soluciones de vanguardia, el acceso a alertas inmediatas suele estar condicionado por elevados costos operativos o dependencia de infraestructura de terceros (celular o satelital). Los trabajos de investigación como AiCatcher [10] y el sistema de Whytock et al. [9] demuestran la viabilidad de la IA para el filtrado en tiempo real, pero enfrentan desafíos en cuanto a consumo energético y costos de transmisión.

En este sentido, se identifica una oportunidad para un sistema que combine la eficiencia en el consumo de los microcontroladores ESP32 con la capacidad de extensión de cobertura de las redes mesh, permitiendo un monitoreo inteligente y de bajo costo operativo adaptado a las condiciones reales observadas en la Selva Misionera.

Capítulo 3

Planteamiento del Problema

3.1. Contexto regional

La provincia de Misiones, ubicada en el extremo noreste de Argentina, alberga uno de los ecosistemas más diversos y amenazados del continente [19]. El marco geográfico de este proyecto se sitúa en el corazón de la selva paranaense, una región que requiere estrategias de conservación urgentes y tecnificadas.

3.1.1. La Selva Misionera y el Bosque Atlántico

La Selva Misionera representa el remanente continuo más extenso del Bosque Atlántico — también conocido como Mata Atlántica— en el Cono Sur. Originalmente, este bioma cubría aproximadamente 1.3 millones de kilómetros cuadrados, extendiéndose desde la costa atlántica de Brasil (92 % de su extensión) hasta el este de Paraguay (6 %) y el noreste de Argentina (2 %) [20].

Sin embargo, debido a siglos de expansión agrícola, ganadera y forestal, hoy solo sobrevive entre el 12 % y 17 % de su extensión original, lo que lo convierte en uno de los hotspots de biodiversidad más amenazados del planeta [19]. Se estima que el Bosque Atlántico ha perdido aproximadamente el 88 % de su cobertura vegetal nativa, siendo reemplazado por paisajes dominados por agricultura, pasturas y áreas urbanas.

Misiones conserva cerca de 1.1 millones de hectáreas de este bosque a través del Corredor Verde, un sistema de áreas protegidas interconectadas que posiciona a la provincia como un refugio crítico para la biodiversidad regional y global [21].

3.1.2. Biodiversidad y especies en peligro

Esta región es hogar de una concentración excepcional de biodiversidad: a pesar de ocupar menos del 0.5 % del territorio argentino, la Selva Misionera alberga más del 50 % de la biodiversidad del país [21]. Se estima que contiene alrededor de 3 000 especies de plantas vasculares, 554 especies de aves, 120 de mamíferos, 79 de reptiles y 55 de anfibios.

Entre las especies más emblemáticas se encuentra el yagüareté (*Panthera onca*), declarado Monumento Natural provincial en 1988 y nacional en 2001. Según el último censo binacional realizado en 2024, se estima una población de aproximadamente 84 individuos en el Corredor Verde entre Argentina y Brasil, con un rango estimado entre 64 y 110 ejemplares [22]. Esta

cifra representa casi la mitad de los menos de 250 yagaretés adultos que se estima sobreviven en todo el territorio argentino.

Otras especies de importancia para la conservación incluyen el tapir (*Tapirus terrestris*), el oso hormiguero gigante (*Myrmecophaga tridactyla*), la yacutinga (*Aburria jacutinga*), el mono caí (*Sapajus nigritus*) y el águila harpía (*Harpia harpyja*). La presencia de estos grandes vertebrados es un indicador clave del estado de salud del ecosistema, pero su monitoreo en densas zonas de selva subtropical es extremadamente complejo.

3.1.3. Importancia ecológica de la región

La importancia de la Selva Misionera trasciende la mera preservación de especies; actúa como regulador climático, protector de cuencas hídricas y proveedor de servicios ecosistémicos esenciales para la región, incluyendo la regulación del ciclo hidrológico, el secuestro de carbono y la protección contra la erosión del suelo.

El marco legal para la protección de estos ecosistemas está dado por la Ley 26.331 de Presupuestos Mínimos de Protección Ambiental de los Bosques Nativos [23], que establece un sistema de ordenamiento territorial basado en tres categorías de conservación:

Categoría I (Rojo): Sectores de muy alto valor de conservación que no deben transformarse. En Misiones, gran parte del Corredor Verde se encuentra clasificado en esta categoría.

Categoría II (Amarillo): Sectores de mediano valor de conservación donde se permite el aprovechamiento sostenible y la restauración.

Categoría III (Verde): Sectores de bajo valor de conservación que pueden transformarse parcialmente.

La provincia de Misiones gestiona actualmente 104 áreas naturales protegidas que suman aproximadamente 1.1 millones de hectáreas, lo que impone la necesidad de una vigilancia constante para evitar la degradación de estas áreas protegidas frente a actividades ilícitas como la caza furtiva y la tala clandestina.

3.2. Problemáticas de conservación en la región

A pesar de los esfuerzos institucionales y del marco legal establecido por la Ley 26.331 [23], las áreas protegidas de Misiones enfrentan amenazas persistentes que comprometen la integridad de sus ecosistemas.

3.2.1. Deforestación y fragmentación del hábitat

La pérdida de cobertura boscosa por actividades agrícolas no autorizadas y la extracción ilegal de madera noble continúan siendo problemas recurrentes. Un estudio de la Facultad de Agronomía de la Universidad de Buenos Aires reveló que entre 1990 y 2020 se perdieron aproximadamente 130 000 hectáreas de bosque nativo solo en el Corredor Verde, lo que representa un 13 % del área original [24]. El análisis indica que el 77 % de la deforestación ocurre en parcelas menores a 50 hectáreas, frecuentemente asociadas a ocupaciones espontáneas para cultivos de subsistencia.

Si bien las políticas de control han mostrado resultados positivos —con una reducción del 18 % en la deforestación durante 2025, alcanzando 4 118 hectáreas anuales frente al promedio histórico de 5 000 hectáreas [25]—, la fragmentación del hábitat sigue obligando a las especies de gran tamaño, como el yaguararé, a desplazarse por áreas no protegidas. Esto aumenta el riesgo de conflictos con humanos, atropellamientos en rutas, y reduce la viabilidad genética de las poblaciones aisladas.

3.2.2. Caza furtiva y tráfico de fauna

La caza furtiva representa uno de los mayores desafíos para la conservación en la región. A pesar de la prohibición total de la caza en la provincia, la incursión de cazadores en el interior de parques provinciales y reservas privadas es frecuente [26]. El problema presenta dos dimensiones principales: una cultural, llevada a cabo por residentes locales como actividad de subsistencia, y otra de carácter económico, impulsada por grupos organizados que buscan especies valiosas para el tráfico de fauna.

Los puntos más críticos se concentran en las zonas fronterizas con Brasil, especialmente en áreas como la reserva de biosfera Yabotí y los parques provinciales Piñalito, Urugua-í y Horacio Foerster. Entre las especies más afectadas se encuentran el tapir (*Tapirus terrestris*), la paca (*Cuniculus paca*), corzuelas, y aves como tucanes, guacamayos y loros. Los cazadores utilizan técnicas de acecho, trampas y cebaderos que no solo afectan a las especies objetivo, sino que degradan la fauna en su totalidad y ponen en riesgo la seguridad de los guardaparques durante los operativos de control.

3.2.3. Intrusión en áreas protegidas

La falta de un control perimetral efectivo en las más de 106 áreas protegidas de la provincia permite la entrada de personas y vehículos no autorizados para actividades ilícitas. Entre las más frecuentes se encuentran:

- Pesca ilegal en cursos de agua dentro de reservas.
- Desmonte encubierto para expansión de cultivos.
- Instalación de campamentos de caza con infraestructura permanente.

Sin un sistema de alerta temprana, estas intrusiones frecuentemente solo se descubren a posteriori durante patrullajes de rutina, cuando el daño ambiental ya ha sido perpetrado y los responsables se encuentran lejos del área.

3.2.4. Desafíos de la vigilancia en el terreno

La vigilancia efectiva de áreas protegidas en la Selva Misionera enfrenta obstáculos inherentes a las características del terreno y la extensión de las superficies a cubrir. Con aproximadamente 780 000 hectáreas distribuidas en más de 106 áreas protegidas, cualquier estrategia de monitoreo debe contemplar las siguientes limitaciones:

Extensión y accesibilidad: Las vastas superficies boscosas presentan terreno accidentado, cursos de agua y vegetación densa que dificultan el desplazamiento y limitan el alcance de las patrullas terrestres.

Cobertura de comunicaciones: La ausencia de infraestructura celular en zonas profundas de selva impide la comunicación en tiempo real y la coordinación de respuestas ante eventos detectados.

Latencia en la detección: El uso de cámara trampa tradicionales, si bien genera datos valiosos para investigación, almacena las imágenes localmente en tarjetas de memoria que deben ser retiradas físicamente, introduciendo demoras de semanas o meses entre la captura y el análisis.

Volumen de datos: Las cámaras convencionales generan grandes cantidades de imágenes, muchas disparadas por movimiento de vegetación o fauna no relevante, requiriendo un esfuerzo manual significativo para su revisión.

Estas limitaciones evidencian la necesidad de sistemas tecnológicos capaces de transmitir alertas en tiempo real, extender la cobertura de comunicaciones mediante redes autoorganizadas, y filtrar automáticamente las imágenes relevantes mediante técnicas de IA.

3.3. Sistemas de monitoreo actuales

Actualmente, el monitoreo biológico y de vigilancia en las áreas protegidas de Misiones emplea una combinación de métodos tradicionales que, si bien han demostrado ser efectivos para la investigación científica, presentan brechas operativas significativas cuando se aplican a la seguridad ambiental y la detección de actividades ilícitas.

3.3.1. Cámaras trampa convencionales

El uso de cámara trampa pasivas constituye el estándar de referencia para el monitoreo de fauna silvestre a nivel mundial [13]. Estos dispositivos se instalan en puntos estratégicos —senderos de fauna, fuentes de agua, zonas de paso— y capturan imágenes automáticamente mediante sensores de calor y movimiento (sensor PIR).

Las cámara trampa tradicionales presentan las siguientes características operativas:

- **Autonomía energética:** Funcionan con baterías AA o paneles solares, permitiendo operación autónoma durante meses.
- **Almacenamiento local:** Las imágenes se guardan en tarjetas SD que deben ser retiradas físicamente para su análisis.
- **Activación pasiva:** El sensor Infrarrojo Pasivo (PIR) detecta cambios de temperatura asociados al movimiento de animales o personas.
- **Operación silenciosa:** Los modelos con flash infrarrojo (Infrarrojo (IR)) permiten capturas nocturnas sin alertar a la fauna.

En Misiones, estas cámaras son utilizadas tanto por organismos gubernamentales como por organizaciones de conservación para el monitoreo del yaguararé, realizar censos de fauna, y documentar la biodiversidad de las reservas [22].

3.3.2. Patrullajes terrestres

Complementariamente, el Cuerpo de Guardaparques realiza patrullajes periódicos a pie, en vehículo o a caballo. Estos recorridos permiten detectar indicios de actividad ilícita (campamentos, trampas, rastros de tala) y establecer presencia disuasoria en las áreas protegidas.

Sin embargo, la efectividad de los patrullajes está limitada por factores logísticos: la densidad de la vegetación restringe la visibilidad, los desplazamientos consumen tiempo considerable, y la cobertura territorial depende directamente de los recursos humanos disponibles.

3.3.3. Brechas tecnológicas identificadas

El análisis de los sistemas actuales revela brechas críticas que limitan la capacidad de respuesta ante eventos de interés:

Latencia en la información: Las imágenes capturadas por cámaras tradicionales permanecen almacenadas localmente durante semanas o meses hasta su recolección. Un evento de caza furtiva registrado por una cámara solo será conocido mucho después de ocurrido, impidiendo cualquier acción disuasoria o legal inmediata.

Clasificación manual: El alto volumen de imágenes capturadas —frecuentemente disparadas por movimiento de vegetación, aves, o pequeños mamíferos no relevantes— demanda cientos de horas-hombre para su revisión y clasificación manual [12].

Ausencia de alertas: Los sistemas actuales no generan notificaciones en tiempo real. La información fluye de manera unidireccional desde el campo hacia los centros de análisis, sin retroalimentación inmediata.

Conectividad limitada: Las soluciones comerciales con transmisión celular, aunque existen en el mercado [16], [17], resultan inviables en las zonas interiores de la selva donde no existe cobertura de red móvil, además de representar costos operativos elevados para despliegues a escala.

Estas brechas fundamentan la necesidad de desarrollar un sistema que combine la robustez de las cámaras de campo con capacidades de transmisión en red, procesamiento automático mediante IA, y generación de alertas en tiempo real.

3.4. Justificación del proyecto

El análisis de las problemáticas de conservación y las limitaciones de los sistemas de monitoreo actuales permite identificar una brecha tecnológica que este proyecto propone abordar.

3.4.1. Urgencia de la problemática

La Selva Misionera representa el último remanente continuo del Bosque Atlántico en Argentina, albergando más del 50 % de la biodiversidad del país en menos del 0.5 % de su territorio [21]. La presión sobre este ecosistema es constante: entre 1990 y 2020 se perdieron 130 000 hectáreas de bosque nativo solo en el Corredor Verde [24], mientras que especies emblemáticas

como el yagüareté mantienen poblaciones críticamente bajas —aproximadamente 84 individuos según el último censo [22].

La caza furtiva, la tala ilegal y la intrusión en áreas protegidas continúan siendo amenazas activas que requieren respuestas inmediatas. Sin embargo, los sistemas de monitoreo actuales operan con latencias de semanas o meses, imposibilitando cualquier acción preventiva o disuasoria.

3.4.2. Oportunidad tecnológica

La convergencia de tres desarrollos tecnológicos recientes crea una oportunidad única para abordar esta problemática:

Microcontroladores de bajo costo: Plataformas como el ESP32 ofrecen capacidades de procesamiento, conectividad Wi-Fi y gestión de energía a costos inferiores a los 10 dólares por unidad, permitiendo despliegues a escala con presupuestos limitados.

Redes mesh autoorganizadas: Protocolos como ESP-MESH permiten extender la conectividad en áreas sin infraestructura celular, creando redes que se adaptan dinámicamente a la topología del terreno y toleran fallos de nodos individuales.

Inteligencia artificial para visión: Modelos de código abierto como SpeciesNet [4] y Mega-Detector [15] permiten clasificar automáticamente imágenes de cámara trampa, distinguiendo fauna silvestre de personas y vehículos con alta precisión.

3.4.3. Requisitos del sistema propuesto

Dada la crítica situación de biodiversidad en Misiones y las brechas identificadas en los sistemas actuales, se justifica el desarrollo de una solución tecnológica que cumpla con los siguientes requisitos:

1. **Bajo costo de implementación:** Permitiendo un despliegue distribuido con presupuesto limitado, utilizando hardware basado en ESP32 y software de código abierto.
2. **Conectividad independiente:** Empleando redes mesh que no requieran infraestructura celular preexistente, adaptándose a la topología irregular de la selva subtropical.
3. **Procesamiento inteligente:** Integrando modelos de IA como SpeciesNet para filtrar y clasificar imágenes automáticamente, reduciendo el volumen de datos a revisar manualmente.
4. **Alertas en tiempo real:** Generando notificaciones inmediatas ante la detección de eventos críticos, ya sea la presencia de fauna en peligro para fines de investigación, o la detección de intrusos para fines de seguridad.

Este proyecto no solo representa un aporte técnico en el área de redes de sensores e IA aplicada a la conservación, sino que constituye una herramienta de aplicación directa para fortalecer la vigilancia de las áreas protegidas de la región, democratizando el acceso a tecnologías de monitoreo inteligente que tradicionalmente han estado reservadas a instituciones con mayores recursos.

Capítulo 4

Objetivos y Alcance

4.1. Objetivo general

Demostrar la viabilidad técnica de un sistema de monitoreo de bajo costo para áreas protegidas, basado en nodos de cámara con conectividad mesh y clasificación automática de imágenes mediante IA. El sistema deberá ser capaz de detectar la presencia de animales, personas y vehículos, así como realizar una clasificación taxonómica de la fauna identificada. Todo esto reduciendo significativamente el tiempo de procesamiento de datos desde días o semanas —típico de las cámaras trampa tradicionales— a minutos.

4.2. Objetivos específicos

1. **Diseñar e implementar un nodo de cámara autónomo** basado en microcontroladores ESP32, capaz de capturar imágenes mediante activación por sensor PIR y transmitirlos a través de una red mesh.
2. **Desarrollar una red mesh autoorganizada** utilizando el protocolo ESP-MESH, que permita extender la conectividad en áreas sin cobertura celular mediante el encadenamiento de nodos intermedios.
3. **Implementar un servidor de procesamiento** capaz de recibir las imágenes transmitidas por la red, clasificarlas automáticamente mediante modelos de IA preentrenados, y generar notificaciones ante la detección de eventos de interés.
4. **Integrar un modelo de clasificación de fauna** como SpeciesNet o MegaDetector, adaptado para identificar las principales categorías de interés: fauna silvestre, personas y vehículos.
5. **Validar el funcionamiento del sistema** en condiciones controladas, evaluando métricas de rendimiento como latencia de transmisión, consumo energético, precisión de clasificación y estabilidad de la red.

4.3. Alcance del proyecto

El presente proyecto tiene como alcance el desarrollo de un prototipo funcional que demuestre la viabilidad del concepto propuesto. Se contemplan los siguientes aspectos:

4.3.1. Dentro del alcance

- Diseño y construcción de nodos de cámara basados en módulos ESP32-CAM con sensor PIR comercial.
- Implementación de la red mesh con capacidad de transmisión de imágenes comprimidas.
- Desarrollo del servidor de recepción, almacenamiento y clasificación de imágenes.
- Integración de un modelo de IA preentrenado para la clasificación automática.
- Sistema de notificaciones mediante bot de Telegram.
- Pruebas de funcionamiento en entorno controlado (laboratorio).
- Validación a pequeña escala en condiciones de campo reales, bajo circunstancias climáticas favorables, dadas las limitaciones de protección del prototipo.

4.3.2. Fuera del alcance

- Despliegue en áreas protegidas reales o ambientes de selva densa.
- Diseño de carcasas con grado de protección IP para uso permanente en exteriores.
- Entrenamiento de modelos de IA específicos para fauna de la región.
- Certificación de equipos para uso comercial o institucional.
- Integración con sistemas de gestión de áreas protegidas existentes.

4.4. Limitaciones

Es importante explicitar las limitaciones técnicas inherentes al prototipo desarrollado, tanto para establecer expectativas adecuadas como para orientar trabajos futuros.

4.4.1. Limitaciones de hardware

Autonomía energética: Los nodos de cámara ESP32 presentan un consumo energético significativo durante la transmisión Wi-Fi. Si bien se implementan estrategias de ahorro de energía, la autonomía con baterías es limitada comparada con cámaras trampa comerciales optimizadas durante años para este propósito. El prototipo utiliza un módulo convertidor buck basado en el circuito integrado LM2596, que permite alimentar el sistema con packs de baterías batería 18650 en diversas configuraciones (2S, 3S, 4S), proporcionando flexibilidad en el voltaje de entrada y permitiendo mayores capacidades de autonomía.

Sensor de movimiento: Se utiliza un sensor PIR domótico convencional, cuyas características de detección están optimizadas para uso en interiores. Esto implica que el sistema es capaz de detectar confiablemente animales de gran porte (tapires, yagaretés, ciervos) y personas, pero puede no activarse consistentemente ante fauna de menor tamaño como aves o pequeños mamíferos.

Operación diurna: El módulo de cámara utilizado incorpora un lente con filtro IR, lo que limita su operación a condiciones de luz diurna. A diferencia de las cámaras trampa comerciales que incluyen iluminación infrarroja para capturas nocturnas, el prototipo desarrollado no cuenta con esta capacidad.

Resolución de imagen: Además de las limitaciones propias del sensor OV2640, los protocolos ESP-MESH y ESP-MDF imponen restricciones en el tamaño máximo de los datos transmitidos por paquete. Esto limita la resolución efectiva de las imágenes que pueden transmitirse a través de la red, requiriendo compresión adicional que afecta la calidad final.

4.4.2. Consideraciones sobre el tiempo de respuesta

Es necesario clarificar el uso del término tiempo real en el contexto de este proyecto. En sistemas embebidos, “tiempo real” típicamente se refiere a la capacidad de responder a eventos dentro de plazos determinísticos estrictos, frecuentemente en el orden de milisegundos o microsegundos.

En el contexto de este proyecto, la noción de tiempo real se utiliza en un sentido operativo diferente: la capacidad de reducir la latencia de procesamiento de imágenes desde **días o semanas** a **minutos**. Los tiempos prolongados característicos de las cámaras trampa tradicionales se deben a la necesidad de desplazarse físicamente hasta cada dispositivo para recolectar las tarjetas de memoria, y posteriormente procesar las imágenes de forma manual o semiautomática. Este cambio de escala temporal, aunque no constituye tiempo real en el sentido determinístico, representa una mejora de varios órdenes de magnitud que habilita respuestas operativas antes imposibles.

4.4.3. Limitaciones de alcance

Rango de comunicación: El alcance de cada nodo mesh depende de las condiciones del terreno y la vegetación. En zonas de selva densa, puede ser necesario un mayor número de nodos intermedios para cubrir distancias equivalentes a las alcanzables en campo abierto.

Ancho de banda: La transmisión de imágenes a través de la red mesh consume ancho de banda significativo. Capturas simultáneas en múltiples nodos pueden generar congestión y aumentar la latencia.

Clasificación de especies: Los modelos de IA utilizados están entrenados con datasets globales que pueden no incluir todas las especies presentes en la Selva Misionera, afectando la precisión de clasificación taxonómica a nivel de especie.

Capítulo 5

Marco Teórico

5.1. Internet de las Cosas (IoT)

El IoT representa un paradigma de conectividad donde objetos físicos —equipados con sensores, capacidad de procesamiento y conectividad de red— intercambian datos con otros dispositivos y sistemas a través de internet o redes locales. Esta tecnología ha experimentado un crecimiento exponencial en las últimas décadas, habilitando aplicaciones que van desde la automatización del hogar hasta el monitoreo ambiental a gran escala [13].

En el contexto de la conservación ambiental, el IoT permite la creación de redes de monitoreo autónomas capaces de operar en ubicaciones remotas con mínima intervención humana. Los sistemas de cámara trampa inteligentes representan una aplicación específica de este paradigma, donde la combinación de sensores, procesamiento embebido y conectividad inalámbrica extiende las capacidades tradicionales de monitoreo de fauna [9].

5.1.1. Arquitecturas IoT

Una arquitectura típica de IoT se compone de tres capas fundamentales:

Capa de Percepción: Formada por los sensores y actuadores que interactúan directamente con el entorno físico. En este proyecto, incluye los sensores PIR y los módulos de cámara.

Capa de Red: Encargada de la transmisión de datos desde los nodos sensores hacia los sistemas de procesamiento. Aquí se implementa la red ESP-MESH que permite la comunicación entre nodos.

Capa de Aplicación: Donde los datos son procesados, almacenados y presentados al usuario final. Corresponde al servidor Django con el modelo de IA y el sistema de notificaciones.

El sistema desarrollado en esta tesis abarca estas tres capas, utilizando nodos ESP32 en la percepción, ESP-MESH en la red y un servidor Django con SpeciesNet en la aplicación.

5.1.2. Protocolos de comunicación inalámbrica

La elección del protocolo de comunicación es crítica en entornos rurales o silvestres donde la infraestructura de red tradicional es inexistente. Cada tecnología presenta compromisos entre alcance, consumo energético y ancho de banda:

Bluetooth Low Energy (BLE): Ideal para corto alcance (hasta 100m) y muy bajo consumo, pero con ancho de banda insuficiente para transmisión de imágenes.

ZigBee: Diseñado para redes de sensores con bajo consumo, pero limitado en velocidad de transferencia y complejidad de implementación.

LoRa/LoRaWAN: Excelente para muy largo alcance (varios kilómetros) con bajo consumo, pero el ancho de banda extremadamente limitado (decenas de bytes por segundo) lo hace inadecuado para transmisión de imágenes [9].

Wi-Fi (802.11): Ofrece alto ancho de banda suficiente para imágenes, pero típicamente requiere infraestructura centralizada y tiene mayor consumo energético.

Las redes mesh basadas en Wi-Fi, como ESP-MESH, ofrecen un equilibrio adecuado: permiten la transmisión de imágenes gracias al ancho de banda del protocolo 802.11, mientras extienden la cobertura sin depender de una única estación base o infraestructura celular preexistente.

5.2. Redes Mesh

Una red de malla o mesh es una topología en la que los nodos se conectan entre sí de forma dinámica, cooperando para propagar los datos a través de la red. Esta arquitectura es especialmente robusta frente a fallos de nodos individuales, ya que la red puede reconfigurarse automáticamente para encontrar rutas alternativas [27].

5.2.1. Topologías de red

Las topologías de red determinan cómo se organizan y comunican los dispositivos:

Topología en estrella: Común en redes Wi-Fi domésticas, donde todos los dispositivos dependen de un único Punto de Acceso central. Si el AP falla, toda la red queda inoperativa.

Topología en árbol: Estructura jerárquica donde existe un nodo raíz que actúa como puerta de enlace hacia redes externas, nodos intermedios que extienden la cobertura, y nodos hoja que únicamente transmiten sus propios datos.

Topología mesh pura: Cada nodo puede comunicarse con múltiples vecinos, creando redundancia en las rutas de comunicación.

ESP-MESH implementa una topología de árbol con capacidades mesh: cada nodo puede actuar simultáneamente como estación (conectada a un padre) y como Punto de Acceso (para nodos hijos), utilizando el modo AP-STA. Esto facilita el despliegue en terrenos difíciles o boscosos, donde los obstáculos físicos limitan la línea de vista directa.

5.2.2. ESP-MESH: características técnicas

ESP-MESH es el protocolo desarrollado por Espressif basado en el estándar IEEE 802.11, que permite conectar cientos de dispositivos ESP32 en una sola red [27]. Sus principales características incluyen:

Autoorganización: Los nodos seleccionan automáticamente su padre óptimo basándose en la intensidad de señal (Received Signal Strength Indicator (RSSI)) y la carga de la red.

Autocuración: Si un nodo intermedio falla o pierde conectividad, sus nodos descendientes buscan y se conectan automáticamente a un nuevo padre, sin intervención manual.

Profundidad configurable: La red puede extenderse hasta una profundidad máxima definida por el usuario (típicamente 6-10 niveles).

Transmisión de datos: Soporta comunicación unicast (a un nodo específico), multicast (a un grupo) y broadcast (a todos los nodos).

5.2.3. Componente Mwifi del ESP-MDF

Mwifi es un componente del ESP-MDF que proporciona una capa de abstracción sobre ESP-MESH, simplificando el desarrollo de aplicaciones. Sus principales aportes incluyen:

- APIs de alto nivel para envío y recepción de datos fragmentados
- Gestión automática de la fragmentación de paquetes grandes (como imágenes) que exceden el tamaño máximo de trama Wi-Fi
- Soporte para transmisión TCP y UDP sobre la red mesh
- Eventos de callback para monitorear el estado de la topología
- Herramientas de depuración integradas

La capacidad de fragmentar y reensamblar datos es crítica para este proyecto, ya que las imágenes capturadas por los nodos exceden significativamente el tamaño máximo de paquete soportado por el protocolo mesh.

5.3. Inteligencia Artificial aplicada a visión por computadora

La visión por computadora busca emular la capacidad humana de interpretar imágenes digitales. Los avances recientes en este campo, impulsados por el aprendizaje automático y específicamente por el aprendizaje profundo (*deep learning*), han revolucionado el procesamiento automático de imágenes de cámara trampa [28].

5.3.1. Redes neuronales convolucionales (CNN)

Las CNNs son arquitecturas de redes neuronales especializadas en procesar datos con estructura de cuadrícula, como las imágenes [29]. Funcionan mediante la aplicación secuencial de filtros convolucionales que extraen características en niveles de abstracción creciente: las primeras capas detectan bordes y texturas básicas, mientras que las capas profundas reconocen patrones complejos como formas de animales o rostros humanos.

Esta capacidad de extracción automática de características —que elimina la necesidad de diseño manual de descriptores— ha convertido a las CNNs en la herramienta fundamental para la clasificación de fauna y la detección de intrusos en imágenes de cámara trampa [12].

5.3.2. Detección de objetos con YOLO

YOLO (*You Only Look Once*) es uno de los algoritmos de detección de objetos más utilizados debido a su velocidad y precisión [2]. A diferencia de métodos tradicionales que analizan una imagen en múltiples pasadas, YOLO trata la detección como un problema de regresión único, prediciendo las bounding boxes y las probabilidades de clase simultáneamente para toda la imagen en una sola evaluación.

La arquitectura YOLOv5 [3], implementada sobre PyTorch, ofrece un excelente equilibrio entre rendimiento computacional y exactitud. Sus variantes (desde YOLOv5n para dispositivos embebidos hasta YOLOv5x para máxima precisión) permiten adaptar el modelo a los recursos disponibles.

5.3.3. MegaDetector

MegaDetector es un modelo de detección desarrollado por Microsoft AI for Earth [15], específicamente diseñado para imágenes de cámara trampa. A diferencia de clasificadores que intentan identificar especies directamente, MegaDetector se enfoca en una tarea más simple: detectar la presencia y ubicación de tres categorías principales:

- Animales (sin distinción de especie)
- Personas
- Vehículos

Esta aproximación en dos etapas —primero detectar, luego clasificar— ha demostrado ser más robusta y generalizable que intentar resolver ambos problemas simultáneamente [11].

5.3.4. SpeciesNet de Google

SpeciesNet es un sistema de IA de código abierto desarrollado por Google [4], diseñado específicamente para el análisis de imágenes de cámara trampa. Combina las capacidades de detección con modelos de clasificación taxonómica entrenados con millones de imágenes de cientos de especies a nivel global.

El pipeline de SpeciesNet opera en dos fases:

1. **Detección:** Identifica regiones de interés en la imagen (animales, personas, vehículos) similar a MegaDetector.

2. **Clasificación:** Para las regiones identificadas como animales, aplica un clasificador taxonómico que predice familia, género y especie.

En este proyecto, SpeciesNet actúa como el núcleo de procesamiento del servidor, validando si las imágenes capturadas por los nodos contienen fauna de interés, personas o vehículos, y generando las alertas correspondientes.

5.4. Tecnologías de desarrollo

Para la implementación del sistema se han seleccionado herramientas que garantizan modularidad, facilidad de mantenimiento e interoperabilidad, priorizando tecnologías de código abierto cuando sea posible.

5.4.1. Microcontroladores ESP32

El ESP32 es un System on Chip (SoC) de bajo costo diseñado por Espressif Systems, que integra conectividad Wi-Fi (802.11 b/g/n) y Bluetooth en un único chip [30]. Sus principales características técnicas incluyen:

- Procesador Xtensa LX6 de doble núcleo a 240 MHz
- 520 KB de SRAM interna
- Soporte para memoria flash externa (hasta 16 MB)
- Múltiples modos de bajo consumo (deep sleep < 10 μ A)
- Rico conjunto de periféricos: SPI, I2C, UART, ADC, DAC, PWM

La variante ESP32-CAM incorpora un módulo de cámara OV2640 y ranura para tarjeta microSD, proporcionando una plataforma compacta para aplicaciones de captura de imagen con conectividad inalámbrica.

5.4.2. ESP-IDF y ESP-MDF

El ESP-IDF (IoT Development Framework) es el entorno de desarrollo oficial para el ESP32 [27], basado en Free Real-Time Operating System (FreeRTOS). Proporciona control preciso sobre el hardware, gestión de energía y acceso a todas las funcionalidades del chip.

Sobre este entorno, el ESP-MDF (Mesh Development Framework) agrega herramientas específicas para redes mesh:

- Componente Mwifi para comunicación mesh de alto nivel
- Gestión automática de topología y enrutamiento
- Capacidades de actualización remota de firmware Over-The-Air (OTA)
- Herramientas de depuración y monitoreo de red

5.4.3. Contenedorización con Docker

Docker es una plataforma de contenedorización que permite empaquetar aplicaciones junto con todas sus dependencias en unidades estandarizadas llamadas contenedores. El uso de Docker y Docker Compose en este proyecto facilita el despliegue del servidor de procesamiento en cualquier máquina, asegurando que el entorno de ejecución sea idéntico al de desarrollo.

Los componentes del servidor se organizan en contenedores separados:

- Contenedor de SpeciesNet para inferencia de IA
- Contenedor de base de datos PostgreSQL
- Contenedor del backend Django

5.4.4. Framework Django

Django es un framework web de alto nivel escrito en Python que fomenta el desarrollo rápido y un diseño limpio. Se utiliza para construir el servidor central que recibe las imágenes de la red mesh, interactúa con el sistema de IA y gestiona el almacenamiento persistente.

Su arquitectura MVT (Modelo-Vista-Plantilla) permite una separación clara entre la lógica de datos, el procesamiento de solicitudes y la presentación de resultados al usuario.

5.5. Sensores y actuadores

Los componentes físicos periféricos permiten la interacción del nodo con el entorno, detectando eventos y capturando información visual. La selección de estos componentes determina las capacidades y limitaciones del sistema.

5.5.1. Sensores de movimiento PIR

El sensor PIR detecta movimiento mediante la medición de cambios en los niveles de radiación infrarroja emitida por objetos en su campo de visión. El sensor contiene un elemento piroeléctrico dividido en dos zonas: cuando un objeto emisor de calor (como un humano o animal) cruza de una zona a otra, se genera una diferencia de voltaje que activa la detección.

Los sensores PIR domóticos utilizados en este proyecto tienen un rango de detección optimizado para objetos del tamaño de humanos, lo que limita la capacidad de detectar fauna de pequeño porte pero es adecuado para animales medianos y grandes como tapires, yagaretés o ciervos.

5.5.2. Módulos de cámara OV2640

El OV2640 es un sensor de imagen CMOS de 2 megapíxeles fabricado por OmniVision, ampliamente utilizado en aplicaciones embebidas por su bajo costo y consumo moderado. Sus especificaciones técnicas principales incluyen:

- Resolución máxima: 1600×1200 píxeles (UXGA)
- Formatos de salida: Joint Photographic Experts Group (JPEG), RGB565, YUV422

- Interfaz: SCCB (compatible con I2C) para control, paralelo para datos
- Compresión JPEG integrada en hardware
- Consumo típico: 125 mW en operación activa

El módulo está integrado en placas de desarrollo como la ESP32-CAM, que incluye slot para tarjeta microSD, LED flash, y antena Wi-Fi externa opcional. La compresión JPEG en hardware es particularmente útil para reducir el tamaño de las imágenes antes de su transmisión por la red mesh.

El lente incluido en los módulos comerciales típicamente incorpora un filtro IR, lo que limita la operación a condiciones de luz diurna.

5.6. Diseño y fabricación digital

La protección física del hardware es fundamental para la operación del sistema en entornos exteriores, donde los componentes electrónicos están expuestos a condiciones ambientales adversas.

5.6.1. Modelado 3D

El diseño de la carcasa protectora se realiza mediante herramientas de CAD, permitiendo crear estructuras precisas adaptadas a los componentes específicos del nodo. Los requisitos principales del diseño incluyen:

- Protección contra humedad y polvo
- Aperturas dimensionadas para la lente de cámara y sensor PIR
- Espacio para el módulo convertidor buck y conexión a pack de baterías batería 18650 externo
- Puntos de montaje para fijación en árboles o postes
- Acceso a la ranura de tarjeta SD sin desmontar el dispositivo

5.6.2. Fabricación aditiva

La impresión 3D mediante tecnología Modelado por Deposición Fundida (FDM) es la técnica utilizada para materializar los diseños. Esta tecnología permite iterar rápidamente sobre prototipos y fabricar piezas personalizadas sin inversión en moldes.

La selección del material de impresión es crítica para la durabilidad. Para los prototipos de validación de este proyecto se utiliza Ácido Poliláctico (PLA), dado que las pruebas de campo se realizarán bajo condiciones climáticas favorables y no se planea exposición prolongada a la intemperie. Sin embargo, el mismo modelo 3D puede ser fabricado en materiales más resistentes como Tereftalato de Polietileno Glicol (PETG) o Acrilonitrilo Estireno Acrilato (ASA) en fases posteriores de despliegue que requieran operación permanente en exteriores.

Capítulo 6

Metodología

6.1. Enfoque metodológico

El desarrollo de este proyecto siguió un enfoque **iterativo e incremental**, donde cada componente del sistema fue desarrollado, probado y refinado antes de avanzar al siguiente. Esta aproximación permitió identificar y corregir problemas tempranamente, reduciendo el riesgo de fallas críticas en etapas avanzadas.

Se adoptó la metodología ágil Kanban para la gestión del proyecto, caracterizada por:

- Visualización del flujo de trabajo mediante un tablero con columnas (Por hacer, En progreso, En revisión, Completado).
- Limitación del trabajo en progreso para mantener el enfoque en tareas específicas.
- Entrega continua de funcionalidades incrementales.
- Flexibilidad para repriorizar tareas según las necesidades emergentes.

Esta metodología resultó particularmente adecuada para un proyecto que combina hardware y software, donde los ciclos de iteración pueden variar significativamente entre componentes: el desarrollo de firmware requiere ciclos más largos de compilación y flasheo, mientras que el desarrollo del servidor permite iteraciones más rápidas.

6.2. Etapas del desarrollo

El proyecto se estructuró en las siguientes etapas principales, representadas en el diagrama de Gantt de la Figura 6.1:

1. **Investigación y diseño:** Revisión del estado del arte, definición de requisitos y diseño de la arquitectura general del sistema.
2. **Desarrollo del firmware:** Implementación del código para los nodos ESP32, incluyendo captura de imágenes, integración del sensor PIR y comunicación mesh.
3. **Desarrollo del servidor:** Implementación del backend Django, integración con Species-Net y sistema de notificaciones.

4. **Diseño y fabricación de hardware:** Modelado 3D de la carcasa e impresión de prototipos.
5. **Integración:** Conexión de todos los componentes del sistema y verificación del flujo completo de datos.
6. **Pruebas y validación:** Evaluación del sistema en condiciones controladas y de campo.




Figura 6.1: Cronograma de desarrollo del proyecto.

6.3. Herramientas y tecnologías utilizadas

6.3.1. Entorno de desarrollo

Editor de código: Visual Studio Code con extensiones para desarrollo en C/C++ (ESP-IDF), Python y Docker.

Framework de firmware: ESP-IDF y ESP-MDF para el desarrollo del código de los nodos ESP32.

Framework web: Django para el servidor de aplicación.

Bot de notificaciones: Librería `python-telegram-bot` para la implementación del sistema de alertas mediante Telegram.

Contenedorización: Docker y Docker Compose para el despliegue de servicios.

6.3.2. Diseño y fabricación 3D

Software de modelado: Autodesk Fusion 360 con licencia educativa para el diseño de la carcasa del nodo.

Software de laminado: PrusaSlicer para la preparación de modelos 3D y generación de código G para la impresora.

Impresora 3D: Creality Ender 3 con cama caliente, utilizando filamento PLA para los prototipos de validación.

6.3.3. Control de versiones y despliegue

El código fuente del proyecto fue organizado en cuatro repositorios Git alojados en GitHub:

1. Repositorio del firmware para nodos de cámara:
<https://github.com/fabcontigiani/mesh-node-capstone-project>
2. Repositorio del firmware para nodo raíz:
<https://github.com/fabcontigiani/root-node-capstone-project>
3. Repositorio del servidor de aplicación:
<https://github.com/fabcontigiani/server-capstone-project>
4. Repositorio del servidor de inferencia y anotación de imágenes:
<https://github.com/fabcontigiani/wildlife-detection-capstone-project>

6.3.4. Despliegue continuo

Se implementó una estrategia de despliegue continuo mediante GitHub Actions para automatizar las siguientes tareas:

- Construcción automática de imágenes Docker al realizar cambios en las ramas principales de los repositorios.
- Publicación de las imágenes en el registro de contenedores de GitHub (GitHub Container Registry).

Esta automatización garantizó que las versiones desplegadas del servidor siempre correspondieran al código más reciente validado, reduciendo errores humanos en el proceso de despliegue.

6.4. Métricas de evaluación

Para validar el cumplimiento de los objetivos del proyecto, se definieron las siguientes métricas de evaluación:

6.4.1. Métricas de rendimiento de red

Latencia de transmisión: Tiempo transcurrido desde la captura de una imagen en el nodo hasta su recepción completa en el servidor. Se mide en segundos y representa la capacidad del sistema para proporcionar información en tiempos operativamente útiles.

Distancia máxima entre nodos: Distancia física máxima a la cual dos nodos pueden mantener una conexión mesh funcional, medida en metros. Esta métrica determina la densidad de nodos necesaria para cubrir un área determinada.

Estabilidad de la red: Tasa de pérdida de paquetes y frecuencia de reconexiones durante operación prolongada. Una red estable debe mantener tasas de pérdida inferiores al 5 %.

6.4.2. Métricas de clasificación

Precisión de detección: Proporción de imágenes correctamente clasificadas como conteniendo animales, personas, vehículos o imágenes vacías.

Precisión de clasificación taxonómica: Para las imágenes con animales, proporción de especies correctamente identificadas a nivel de familia o género.

6.4.3. Métricas de consumo energético

Consumo promedio del nodo: Consumo eléctrico promedio del nodo de cámara durante un ciclo típico de operación (espera + captura + transmisión), medido en miliamperios (mA).

Autonomía estimada: Tiempo de operación estimado con una batería de capacidad conocida, calculado a partir del consumo promedio.

6.5. Estrategia de pruebas

6.5.1. Pruebas incrementales de firmware

Durante el desarrollo del firmware, cada módulo fue probado de forma aislada antes de su integración:

- Pruebas de captura de imagen con el módulo OV2640
- Pruebas de detección del sensor PIR
- Pruebas de conexión y transmisión mesh entre nodos
- Pruebas de consumo energético

6.5.2. Pruebas de integración

Una vez validados los componentes individuales, se realizaron pruebas de integración verificando:

- Transmisión de imágenes desde nodos de cámara hasta el servidor
- Procesamiento de imágenes por el modelo de IA
- Generación de notificaciones mediante el bot de Telegram

6.5.3. Pruebas de sistema

Las pruebas del sistema completo se realizaron en dos fases:

Fase 1 - Pruebas de laboratorio: Validación del funcionamiento del sistema en condiciones controladas de interior, verificando la correcta integración de todos los componentes y midiendo las métricas de rendimiento base.

Fase 2 - Pruebas de campo: Instalación del sistema en un entorno exterior bajo condiciones climáticas favorables. Durante varias horas se monitoreó el funcionamiento del sistema, registrando las métricas de latencia, estabilidad de red, consumo energético y precisión de clasificación en condiciones realistas.

Capítulo 7

Diseño e Implementación del Sistema

7.1. Arquitectura general

7.2. Nodo de cámara (mesh-node)

7.2.1. Selección de componentes

7.2.2. Diseño del firmware

7.2.3. Captura de imágenes

7.2.4. Integración del sensor PIR

7.2.5. Compresión y transmisión

7.2.6. Carcasa para impresión 3D

7.3. Nodo raíz (root-node)

7.3.1. Diseño del hardware

7.3.2. Firmware del nodo raíz

7.3.3. Conexión con servidor TCP

7.3.4. Gestión de la red mesh

7.4. Red mesh

7.4.1. Topología de la red

7.4.2. Protocolo de comunicación

7.4.3. Formato de datos

7.5. Servicio de detección (wildlife-detection)

7.5.1. Arquitectura del servicio ⁴¹

7.5.2. Contenedor Docker con SpeciesNet

7.5.3. API de inferencia

Capítulo 8

Pruebas y Resultados

8.1. Ambiente de pruebas

8.2. Pruebas de conectividad y red mesh

8.2.1. Alcance de la red

8.2.2. Latencia de transmisión

8.2.3. Estabilidad de la conexión

8.3. Pruebas de detección

8.3.1. Detección de fauna silvestre

8.3.2. Detección de humanos

8.3.3. Detección de vehículos

8.4. Evaluación del modelo de IA

8.4.1. Precisión y recall

8.4.2. Tiempo de inferencia

8.5. Pruebas de consumo energético

8.6. Pruebas del sistema de alertas

8.6.1. Tiempo de respuesta

8.7. Análisis de resultados

Capítulo 9

Conclusiones

9.1. Conclusiones generales

9.2. Aportes del trabajo

9.3. Trabajos futuros

9.4. Recomendaciones

Capítulo 10

Bibliografía

- [1] S. Schneider, G. W. Taylor y S. Kremer, «Deep Learning Object Detection Methods for Ecological Camera Trap Data,» en *2018 15th Conference on Computer and Robot Vision (CRV)*, IEEE, 2018, págs. 321-328. DOI: [10.1109/CRV.2018.00052](https://doi.org/10.1109/CRV.2018.00052).
- [2] J. Redmon, S. Divvala, R. Girshick y A. Farhadi, «You Only Look Once: Unified, Real-Time Object Detection,» *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, págs. 779-788, 2016.
- [3] G. Jocher. «YOLOv5 by Ultralytics.» Repositorio oficial de YOLOv5, visitado 27 de dic. de 2024. dirección: <https://github.com/ultralytics/yolov5>.
- [4] T. Gadot et al., «To crop or not to crop: Comparing whole-image and cropped classification on a large dataset of camera trap images,» *IET Computer Vision*, 2024.
- [5] G. Barrero y A. Schmunck, «Desarrollo de una microcámara de vigilancia para la protección de la fauna salvaje,» Tesis de Grado, Universidad Nacional de Misiones, 2023. dirección: <https://drive.google.com/file/d/1jJDM-Mc8kJw3Rcgl0tf4Mq3MxNyqXW5>.
- [6] F. González et al., «Inteligencia artificial para la multi-clasificación de fauna en fotografías automáticas utilizadas en investigación científica,» en *XXIV Workshop de Investigadores en Ciencias de la Computación (WICC 2022)*, Mendoza, Argentina, abr. de 2022, ISBN: 978-987-48222-3-9. dirección: <https://sedici.unlp.edu.ar/handle/10915/144851>.
- [7] B. S. Z. Abood, M. B. M, Z. A. Almoussawi, N. Shilpa y A. M. Shakir, «Revolutionizing Wildlife Monitoring: A Novel Approach to Camera Trap Image Analysis with YOLOv5,» en *2023 3rd International Conference on Mobile Networks and Wireless Communications (ICMNWC)*, IEEE, dic. de 2023. DOI: [10.1109/ICMNWC60182.2023.10435785](https://doi.org/10.1109/ICMNWC60182.2023.10435785). dirección: <http://dx.doi.org/10.1109/ICMNWC60182.2023.10435785>.
- [8] Y. Njathi, L. Wanjiku, L. Mugambi, J. N. Kabi, G. Kiarie y C. w. Maina, «Efficient Camera Trap Image Annotation Using YOLOv5,» en *2023 IEEE AFRICON*, IEEE, sep. de 2023. DOI: [10.1109/AFRICON55910.2023.10293724](https://doi.org/10.1109/AFRICON55910.2023.10293724). dirección: <http://dx.doi.org/10.1109/AFRICON55910.2023.10293724>.
- [9] R. C. Whytock et al., «Real-time alerts from AI-enabled camera traps using the Iridium satellite network: A case-study in Gabon, Central Africa,» *Methods in Ecology and Evolution*, vol. 14, n.º 3, págs. 867-874, 2023, ISSN: 2041-210X. DOI: [10.1111/2041-210X.14036](https://doi.org/10.1111/2041-210X.14036). dirección: <http://dx.doi.org/10.1111/2041-210X.14036>.

- [10] D. Mallya. «AiCatcher: Extending machine intelligence into the wild,» visitado 27 de dic. de 2024. dirección: <https://deepakmallya.com/aicatcher>.
- [11] J. Vélez et al., «An evaluation of platforms for processing camera-trap data using artificial intelligence,» *Methods in Ecology and Evolution*, vol. 14, n.º 2, págs. 459-477, 2022, ISSN: 2041-210X. DOI: [10.1111/2041-210X.14044](https://doi.org/10.1111/2041-210X.14044). dirección: <http://dx.doi.org/10.1111/2041-210X.14044>.
- [12] M. A. Tabak et al., «Machine learning to classify animal species in camera trap images: Applications in ecology,» *Methods in Ecology and Evolution*, vol. 10, n.º 4, págs. 585-590, 2019. DOI: [10.1111/2041-210X.13120](https://doi.org/10.1111/2041-210X.13120).
- [13] R. Steenweg et al., «Scaling-up camera traps: monitoring the planet's biodiversity with networks of remote sensors,» *Frontiers in Ecology and the Environment*, vol. 15, n.º 1, págs. 26-34, 2017. DOI: [10.1002/fee.1448](https://doi.org/10.1002/fee.1448).
- [14] A. Hernandez, Z. Miao, L. Vargas, R. Dodhia y J. Lavista, *Pytorch-Wildlife: A Collaborative Deep Learning Framework for Conservation*, 2024. arXiv: [2405.12930](https://arxiv.org/abs/2405.12930) [cs.CV]. dirección: <https://arxiv.org/abs/2405.12930>.
- [15] S. Beery, D. Morris y S. Yang, «Efficient Pipeline for Camera Trap Image Review,» *arXiv preprint arXiv:1907.06772*, 2019. dirección: <https://arxiv.org/abs/1907.06772>.
- [16] Tactacam. «Tactacam REVEAL Cellular Cameras,» visitado 27 de dic. de 2024. dirección: <https://www.revealcellcam.com/>.
- [17] Spypoint. «Spypoint Cellular Trail Cameras,» visitado 27 de dic. de 2024. dirección: <https://www.spypoint.com/>.
- [18] Wildlife Insights. «Wildlife Insights: A cloud-based platform for camera trap data,» visitado 27 de dic. de 2024. dirección: <https://www.wildlifeinsights.org/>.
- [19] World Wildlife Fund. «Atlantic Forest: The most threatened tropical forest,» visitado 27 de dic. de 2024. dirección: <https://www.worldwildlife.org/places/atlantic-forest>.
- [20] M. C. Ribeiro, J. P. Metzger, A. C. Martensen, F. J. Ponzoni y M. M. Hirota, «The Brazilian Atlantic Forest: How much is left, and how is the remaining forest distributed? Implications for conservation,» *Biological Conservation*, vol. 142, n.º 6, págs. 1141-1153, 2009. DOI: [10.1016/j.biocon.2009.02.021](https://doi.org/10.1016/j.biocon.2009.02.021).
- [21] M. S. Di Bitetti, G. Placci y L. A. Dietz, «A Biodiversity Vision for the Upper Paraná Atlantic Forest Ecoregion: Designing a Biodiversity Conservation Landscape and Setting Priorities for Conservation Action,» *World Wildlife Fund*, 2003.
- [22] Fundación Vida Silvestre Argentina. «Censo de Yaguareté 2024: Resultados del monitoreo binacional en el Corredor Verde,» visitado 27 de dic. de 2024. dirección: <https://www.vidasilvestre.org.ar/>.
- [23] Congreso de la Nación Argentina, *Ley 26.331 de Presupuestos Mínimos de Protección Ambiental de los Bosques Nativos*, Boletín Oficial de la República Argentina, Sancionada el 28 de noviembre de 2007, 2007.
- [24] Facultad de Agronomía, Universidad de Buenos Aires. «Estudio sobre pérdida de bosque nativo en el Corredor Verde de Misiones (1990-2020),» visitado 27 de dic. de 2024. dirección: <https://www.agro.uba.ar/>.

- [25] Ministerio de Ecología y Recursos Naturales Renovables de Misiones. «Informe de Deforestación 2025: Misiones alcanzó el nivel más bajo de pérdida de bosque nativo,» visitado 27 de dic. de 2024. dirección: <https://ecologia.misiones.gob.ar/>.
- [26] Ministerio de Ecología y Recursos Naturales Renovables de Misiones. «Programa de Control de Caza Furtiva: En Misiones NO se caza,» visitado 27 de dic. de 2024. dirección: <https://ecologia.misiones.gob.ar/>.
- [27] Espressif Systems. «ESP-MESH Programming Guide,» visitado 15 de ene. de 2024. dirección: <https://docs.espressif.com/projects/esp-idf/en/latest/esp32/api-guides/esp-wifi-mesh.html>.
- [28] M. S. Norouzzadeh et al., «Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning,» en *Proceedings of the National Academy of Sciences*, vol. 115, 2018, E5716-E5725.
- [29] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. dirección: <http://www.deeplearningbook.org>.
- [30] Espressif Systems, *ESP32 Technical Reference Manual*, Espressif Systems, 2023. dirección: https://www.espressif.com/sites/default/files/documentation/esp32_technical_reference_manual_en.pdf.

Apéndice A

Esquemáticos del hardware

Apéndice B

Código fuente relevante

- B.1. Firmware del nodo mesh
- B.2. Firmware del nodo raíz
- B.3. Servidor de detección
- B.4. Aplicación Django

Apéndice C

Manual de instalación y configuración

C.1. Configuración del firmware

C.2. Despliegue del servidor

C.3. Configuración del bot de Telegram

Apéndice D

Manual de usuario

Apéndice E

Especificaciones técnicas

Apéndice F

Análisis de viabilidad económica